INEM · 2026–2027 · COURS DE SYNTHÈSE

IA pour les systèmes embarqués
Du besoin à la preuve

Roland Cédric TAYO · 180 minutes, pause comprise.

Comprendre pourquoi calculer à bord, lire les briques d'un modèle, repérer les contraintes matérielles et défendre une optimisation à partir de résultats reproductibles. Le cours relie des fondations durables à des publications de 2023–2026, avec quelques repères historiques nécessaires.

Parcours de trois heures

Créneau	Objet	Preuve de compréhension
0–27 min	Besoin et histoire sélective	Justifier local, distant ou hybride.
27–67 min	Données, dense, convolution, état, attention et gradients	Identifier poids, activations, MAC et cache.
67–97 min	Matériel, mémoire, délai et énergie	Distinguer payload, pic RAM et coût système.
97–107 min	Pause	10 minutes incluses.
107–139 min	Quantifier, compresser et réorganiser	Expliquer un gain local et sa limite globale.
139–180 min	Déployer, tester, maîtriser les risques et enquêter	Formuler une expérience et ses limites.

Modalité

44 diapositives dans le parcours oral ; 10 annexes de références, lexique et réponses hors parcours. Cinq questions collectives et démonstrations sur les MAC, la mémoire, la quantification, le cache KV et le gain global. Les temps indiqués comprennent les échanges ; ne pas ajouter la lecture des annexes aux trois heures.

Prérequis et portée

Fonctions et tableaux, bases CPU/mémoire, vecteurs/matrices, moyenne/variance. Ce cours fournit une grille de lecture ; la maîtrise se construit dans le TD, le déploiement et les mesures sur une cible identifiée. Il ne constitue pas une qualification en sûreté ou un cours complet d'apprentissage profond.

Ce que l’étudiant doit pouvoir expliquer

1. Relier un service attendu à un budget de qualité, mémoire, temps et énergie.
2. Distinguer entraînement, inférence, modèle, runtime et noyau matériel.
3. Expliquer le rôle et le coût des principales briques, sans tout réduire au nombre de paramètres.
4. Choisir une optimisation à partir d’un goulot mesuré et vérifier sa correction.
5. Lire une publication en identifiant cible, tâches, comparaison, compromis et limites.
6. Décrire une chaîne déployable et son comportement en cas d’entrée inattendue ou de délai dépassé.

Trois lectures récentes à approfondir

Architecture : Qin et al., MobileNetV4, ECCV 2024. Quels matériels sont évalués ? Où sont les compromis ?

Représentation : Lin, Tang et al., AWQ, MLSys 2024. Qu’est-ce qui est quantifié ? Quel noyau transforme la compression en vitesse ?

Exécution : Wei et al., T-MAC, EuroSys 2025. Quand une table remplace-t-elle utilement un produit ? Que coûte sa préparation ?

Veille et prudence

T-MAN (2025), FastGRNN sur MCU (2026) et accélération Transformer sur RISC-V (octobre 2026) illustrent des pistes actuelles. Les versions arXiv consultées sont signalées comme prépublications ; leur statut de publication évaluée n’est pas établi ici. Aucun gain n’est présenté comme universel.

Du cours au TD

Programmer le petit Mixer et ses gradients, entraîner et comparer aux références, porter l’inférence, puis étudier une projection dense avec poids fixés. Relier chaque mesure aux sources, versions et conditions. Une absence de gain peut produire une excellente analyse.

Bibliographie complète : annexes de la présentation, SOURCES.md, references.json et references.bib. Les illustrations sont originales ; les chiffres de démonstration sont explicitement analytiques ou fictifs. Aucun résultat du corrigé enseignant n’est révélé dans ce cours.